

Benchmark reproduzível de métodos clássicos de aprendizado de máquina para diagnóstico de falhas no Tennessee Eastman Process

Grupo A — WP1A / MEI0028 — Modelagem e Simulação
Pontifícia Universidade Católica de Goiás

2026-09-14

Abstract

Este artigo apresenta um benchmark reproduzível de seis famílias clássicas de aprendizado de máquina — regressão logística, árvore de decisão, random forest, gradient boosting, SVM e XGBoost — para diagnóstico multiclasse de falhas no Tennessee Eastman Process (TEP). O protocolo fixa a execução do processo (run) como unidade de divisão e de análise, exige o mesmo manifesto e o mesmo pré-processamento para todos os modelos, isola o conjunto de teste até o congelamento das configurações e avalia desempenho e custo de forma multicritério. No experimento oficial exp-a4-v2, random forest, XGBoost e gradient boosting lideram as métricas globais no teste; regressão logística e SVM linear formam o grupo inferior. O líder em acurácia (XGBoost, 0,618) não coincide com o líder em F1 macro e MCC (random forest, 0,357 e 0,597). Entre classes presentes no holdout, as falhas 3, 15 e 10 são as de menor F1 médio; as confusões 10→15 e 3→15 são as mais frequentes. Pelos critérios binários de SPEC-000 §4 no holdout, H1-H4 são *corroboradas*. Em nível de execução (SPEC-008; acurácia por run, $n=11$), Friedman rejeita igualdade global ($p=0,015$); Wilcoxon+Holm na família H1 corrobora ensembles>LR, enquanto a família H2 não corrobora RF/XGB>DT. Ameaças estruturais incluem cobertura disjunta de classes entre validação e teste (dois runs por classe no dataset canônico), somente/split únicos e orçamentos de busca desiguais. O benchmark destina-se a servir de referência clássica para estudos futuros com modelos profundos, físico-informados ou de detecção precoce.

Contents

1	Introdução	3
2	Fundamentação sobre diagnóstico de falhas e TEP	3
2.1	Diagnóstico de falhas orientado a dados	3
2.2	Tennessee Eastman Process	4
2.3	Avaliação multicritério	4
3	Trabalhos relacionados	4
4	Materiais e métodos	4
4.1	Dataset canônico	4
4.2	Divisão agrupada por execução	4

4.3	Pré-processamento	5
4.4	Modelos	5
4.5	Seleção de hiperparâmetros	6
4.6	Métricas	6
5	Protocolo reprodutível	6
6	Resultados	7
6.1	Desempenho global e custo	7
6.2	QP1 — Desempenho global	7
6.3	QP2 — Equilíbrio entre classes	8
6.4	QP3 — Falhas difíceis	8
6.5	QP4 — Complexidade versus custo	9
6.6	QP5 — Compromisso multicritério	9
6.7	Análise estatística (SPEC-008)	10
6.8	Avaliação de H1-H4	10
7	Discussão	10
8	Ameaças à validade	10
8.1	Validade interna	10
8.2	Validade estatística	11
8.3	Validade de constructo	11
8.4	Validade externa	11
8.5	Reprodutibilidade (transversal)	11
8.6	Riscos metodológicos aceitos (ACCEPTED RISK)	11
9	Conclusões	12
10	Referências	12

1 Introdução

O diagnóstico automático de falhas em processos químicos industriais exige mapear variáveis de processo a condições operacionais (normal versus modos de falha) com protocolo experimental transparente. Comparações entre classificadores frequentemente misturam partições inconsistentes, permitem vazamento temporal entre treino e teste e concluem “melhor modelo” apenas por acurácia simples — métrica frágil sob desbalanceamento entre classes [1, 2].

O Tennessee Eastman Process (TEP) [3] é um ambiente simulado de referência com 52 variáveis de processo e 21 classes (condição normal e 20 falhas). Este trabalho desenvolve um **benchmark reproduzível** de seis famílias clássicas de aprendizado de máquina sob um único protocolo, respondendo a cinco questões de pesquisa (QP1-QP5) e avaliando quatro hipóteses (H1-H4).

Contribuições. (i) protocolo anti-vazamento com divisão agrupada por execução; (ii) avaliação conjunta de desempenho e custo computacional (proibição de ranking por métrica única); (iii) artefatos versionados (manifesto, previsões, métricas, figuras) que permitem recomputar qualquer número reportado; (iv) respostas explícitas a QP1-QP5 e vereditos binários (corroborada/refutada) de H1-H4, com evidência §4 no holdout e testes SPEC-008 em nível de `run_id`.

Questões de pesquisa.

QP1 Quais algoritmos apresentam o melhor desempenho global?

QP2 O desempenho é consistente sob equilíbrio entre classes?

QP3 Quais falhas são sistematicamente mais difíceis?

QP4 Métodos mais complexos justificam maior custo?

QP5 Qual o melhor compromisso desempenho $\times$ tempo $\times$ tamanho?

Hipóteses.

H1 Conjuntos baseados em árvores superam regressão logística em F1 macro e/ou MCC.

H2 XGBoost e random forest superam regressão logística e árvore isolada em F1 e MCC.

H3 Regressão logística permanece competitiva em custo, com F1 reduzido nas falhas difíceis.

H4 O melhor modelo por acurácia não coincide com o melhor por F1, MCC ou custo de inferência.

2 Fundamentação sobre diagnóstico de falhas e TEP

2.1 Diagnóstico de falhas orientado a dados

Métodos clássicos de monitoramento e diagnóstico (PCA dinâmico, CVA, PLS e variantes) exploram correlação entre variáveis para detecção e, em alguns casos,

isolamento de falhas [4, 1]. Abordagens de aprendizado supervisionado tratam o problema como classificação multiclasse: cada observação recebe um rótulo de condição operacional. A qualidade da conclusão depende criticamente da unidade amostral usada na divisão e nos testes estatísticos.

2.2 Tennessee Eastman Process

O TEP [3] simula uma planta com reator, condensador, separador, stripper e reciclo. Cada execução (*run*) induz (ou não) uma falha e gera uma série temporal de observações. No presente estudo, a tarefa é classificar vetores de 52 variáveis em uma de 21 classes. A **unidade experimental** é a execução, não a linha individual: observações do mesmo run são temporalmente correlacionadas e não podem ser tratadas como amostras independentes na divisão nem nos testes de hipótese (INV-09; UE-03).

2.3 Avaliação multicritério

Em cenários com 21 classes e desbalanceamento, acurácia simples pode mascarar fracasso em falhas minoritárias. Adotamos o conjunto de métricas globais (acurácia, acurácia balanceada, precisão/revocação/F1 macro, F1 ponderada, MCC), métricas por classe, matrizes de confusão e custos (tempo de treino, tempo de inferência, tamanho do modelo). Nenhuma conclusão de superioridade se apoia apenas em acurácia [5].

3 Trabalhos relacionados

Yin et al. [2] comparam métodos data-driven no TEP e evidenciam a sensibilidade dos resultados ao protocolo. Conjuntos de dados derivados do TEP ampliaram o uso em detecção de anomalias [6]. Ensembles de árvores [7] e boosting escalável [8], bem como SVMs [9], são famílias clássicas recorrentes em classificação tabular.

O presente trabalho diferencia-se por: (1) fixar a execução como unidade de divisão com verificação automatizada de disjunção; (2) obrigar o mesmo pipeline para seis modelos; (3) isolar o teste até o congelamento; (4) reportar custo sempre que se discute “melhor modelo”; (5) delimitar explicitamente o escopo aos métodos clássicos, como referência para estudos futuros com redes profundas ou modelos físico-informados — fora do escopo deste benchmark.

4 Materiais e métodos

4.1 Dataset canônico

Utilizamos a versão canônica `tep-canonical-v1`: 52 atributos, 21 classes, 42 execuções e 30 260 linhas (Tabela 1; Figura 1). A auditoria prévia do pacote bruto e o registro canônico precedem qualquer modelagem.

4.2 Divisão agrupada por execução

A estratégia `stratified_one_train_per_class_remaining_split_val_test` reserva um run por classe ao treino e divide o restante aproximadamente 50/50 entre validação e teste (semente 42). Resultado: 21 runs de treino, 10 de validação e 11 de teste. A checagem de interseção vazia de `run_id` passou no manifesto A3.

Table 1: Sumário do dataset canônico (artefato A6; article/tables/A6_exp-a4-v2__01_dataset_summary.csv).

Item	Valor
Features	52
Classes	21
Runs	42
Linhas	30 260
Versão	tep-canonical-v1




Figure 1: Caracterização do dataset (A6). Fonte: results/ via gerador A6 (sem leitura de data/raw).

Limitação estrutural. Com apenas dois runs por classe, validação e teste **não cobrem simultaneamente as 21 classes**. Neste experimento, os conjuntos de classes de validação e de teste são disjuntos (validação: classes 0, 1, 4, 5, 7, 8, 9, 12, 16, 17; teste: 2, 3, 6, 10, 11, 13, 14, 15, 18, 19, 20). Essa limitação é discutida na Seção 8.

4.3 Pré-processamento

A versão `preprocessor_v1` ajusta transformações dependentes dos dados (padronização) **exclusivamente no treino** e apenas aplica (`transform`) validação e teste.

4.4 Modelos

Seis classificadores sob o mesmo manifesto e o mesmo pré-processamento (implementação via `scikit-learn` [10] e `XGBoost` [8]):

1. Regressão logística (MOD-1)
2. Árvore de decisão (MOD-2)

3. Random forest (MOD-3) [7]
4. Gradient boosting sklearn (MOD-4)
5. SVM linear (MOD-5) [9]
6. XGBoost (MOD-6) [8]

4.5 Seleção de hiperparâmetros

A busca usa apenas treino/validação. Os espaços desta baseline (exp-a4-v2) são reduzidos e **desiguais** entre famílias (p.ex. gradient boosting com dois candidatos; SVM restrito a kernel linear; XGBoost com oito candidatos). Hiperparâmetros congelados: Tabela 2.

Table 2: Hiperparâmetros finais (A6; A6_exp-a4-v2__02_hyperparameters.csv).

Modelo	Parâmetros principais
Regressão logística	$C=10$, lbfgs, max_iter=1000
Árvore de decisão	max_depth=20, min_samples_leaf=5
Random forest	$n=200$, max_depth=20
Gradient boosting	$n=50$, $\eta=0,1$, max_depth=3
SVM	$C=10$, kernel linear
XGBoost	$n=100$, $\eta=0,1$, max_depth=6, hist

4.6 Métricas

Reportamos MET-01 a MET-12. F1 macro e acurácia balanceada usam $C=21$: classes ausentes no teste entram com contribuição nula e deprimem essas métricas em relação à acurácia. Verificação formal das definições: formula_checks_ok=True nos seis modelos (results/tables/A5_exp-a4-v2__global_metrics.csv).

5 Protocolo reprodutível

O pipeline segue a ordem fixa: auditoria → análise exploratória → divisão → pré-processamento → treinamento/seleção → avaliação final. O experimento oficial é exp-a4-v2 (substitui exp-a4-v1, abortado por custo no gradient boosting).

- Semente: 42 (configs/seeds.yaml).
- Manifesto: data/processed/split_manifest_v1.json.
- Configuração: configs/experiments/exp-a4-v2.yaml.
- Snapshot de ambiente: Python 3.12.7, scikit-learn 1.9.1, XGBoost 2.1.4 (results/metadata).
- SHA de execução A4: 40c6c6026f39... (git_dirty: true no snapshot).
- Predições e métricas brutas em results/; figuras/tabelas de publicação em article/ (geradas somente a partir de results/).

Um *dry-run* com fração de runs existe para fumaça de pipeline e está marcado como não científico (scientific_validity: false); não alimenta este manuscrito. Tuning ampliado (SPEC-006A) não foi executado nesta baseline.

6 Resultados

Todos os números abaixo provêm de `results/tables/A5_exp-a4-v2__*.csv` e das figuras A6 correspondentes.

6.1 Desempenho global e custo

A Tabela 3 e as Figuras 2-3 resumem o teste.

Table 3: Métricas globais e custo no conjunto de teste (A5_exp-a4-v2__global_metrics.csv).

Modelo	Acc	BA	$F1_m$	MCC	Treinos	Inf.s	Bytes
Reg. logística	0,275	0,164	0,184	0,250	3,65	0,003	10 020
Árvore	0,564	0,303	0,314	0,560	1,36	0,0015	158 662
Random forest	0,617	0,333	0,357	0,597	3,09	0,243	49 567 094
Grad. boosting	0,608	0,321	0,347	0,584	281,89	0,101	1 901 442
SVM linear	0,237	0,150	0,163	0,215	177,03	3,575	8 782 836
XGBoost	0,618	0,330	0,353	0,596	22,28	0,052	4 910 294




Figure 2: Comparativo de F1 macro e MCC (A6).

6.2 QP1 — Desempenho global

Os conjuntos baseados em árvores (RF, XGBoost, GB) e, em seguida, a árvore isolada dominam as métricas globais; regressão logística e SVM linear formam o grupo inferior. Por acurácia lidera XGBoost (0,618); por F1 macro e MCC lidera random forest (0,357 e 0,597). Não há ranking oficial por métrica única.




Figure 3: Custo computacional: treino, inferência e tamanho (A6).

6.3 QP2 — Equilíbrio entre classes

O ranking por acurácia ($XGB \rightarrow RF \rightarrow GB \rightarrow DT \rightarrow LR \rightarrow SVM$) **não** coincide com o ranking por BA/F1/MCC ($RF \rightarrow XGB \rightarrow \dots$). A diferença XGB-RF é pequena, mas suficiente para afirmar inconsistência parcial entre critérios. A lacuna acurácia $\gg$ BA/F1 é compatível com a média sobre 21 classes incluindo 10 ausentes no teste.

6.4 QP3 — Falhas difíceis

Entre classes com $\text{support} > 0$, os menores F1 médios (seis modelos) ocorrem nas falhas **3** (0,184), **15** (0,252) e **10** (0,283). Pares mais frequentes (soma entre modelos): 10 $\rightarrow$ 15 (1451), 3 $\rightarrow$ 15 (1002), 18 $\rightarrow$ 5 (1001), 13 $\rightarrow$ 12 (809) (Figuras 4-5; A5_exp-a4-v2_qp3_confused_faults.json). Classes com $\text{support}=0$ não são interpretadas como “difíceis observadas” neste holdout. Não atribuímos mecanismo físico a essas confusões.




Figure 4: Pares de confusão mais frequentes (A6).

Matrizes de confusão por modelo estão em `article/figures/A6_exp-a4-v2__05_cm__*.png`




Figure 5: Heatmap de F1 por classe (NaN onde support=0) (A6).

6.5 QP4 — Complexidade versus custo

RF obtém o melhor F1/MCC com treino baixo, porém o maior artefato. XGBoost quase empata RF com inferência mais rápida e tamanho cerca de 10× menor. GB não supera RF/XGB e tem o maior tempo de treino (≈ 282 s): o ganho observado não justifica esse custo nesta baseline. SVM linear combina custo alto e pior desempenho preditivo.

6.6 QP5 — Compromisso multicritério

- Maximizar F1/MCC: **random forest**.
- Compromisso desempenho/custo: **XGBoost**.
- Extremo barato com desempenho intermediário: **árvore de decisão**.
- Extremo compacto com desempenho global baixo: **regressão logística**.

6.7 Análise estatística (SPEC-008)

Unidade experimental: run_id; $n=11$ runs de teste; métrica pareada: acurácia dentro do run (run_accuracy). Fonte: results/tables/A8_exp-a4-v2__* e results/metrics/A8_

Friedman (6 modelos): $\chi^2=14,079$, $p=0,015$ — rejeita igualdade global de ranks. Médias de run_accuracy: RF 0,635, XGB 0,630, GB 0,614, DT 0,579, LR 0,313, SVM 0,287.

Wilcoxon com Holm *dentro* de cada família planejada: H1 (3 pares RF/GB/XGB vs LR) — todos significativos; H2 (4 pares RF/XGB vs LR/DT) — **nenhum** dos quatro pares permanece significativo após Holm (incluindo RF/XGB vs LR nesta família de tamanho 4, ao contrário da família H1 de tamanho 3; as diferenças médias vs DT são as menores). Poder limitado por $n=11$. Limitação: uma semente e um split (EST-01 entre sementes não aplicável).

6.8 Avaliação de H1-H4

H1 RF, GB e XGB superam LR em F1/MCC globais (§4). **Corroborada** (§4). Run-level: **corroborada** (Wilcoxon+Holm, família H1).

H2 RF e XGB superam LR e DT em F1/MCC globais (§4). **Corroborada** (§4). Run-level: **não corroborada** (Wilcoxon+Holm na família de 4 pares: nenhum significativo após correção).

H3 LR entre os de menor custo e F1 reduzido nas falhas difíceis presentes. **Corroborada** (§4; Wilcoxon de acurácia por run não é o teste primário).

H4 Líderes distintos: XGB (acurácia), RF (F1/MCC), DT (inferência). **Corroborada** (§4; multicritério, sem contraste Wilcoxon único).

7 Discussão

Os resultados reforçam que **escolha de modelo é multicritério**: acurácia, F1/MCC e custo produzem líderes distintos (H4). Ensembles superam LR de forma consistente no holdout e no Wilcoxon H1; a família H2 (4 pares) **não** corrobora RF/XGB em run_accuracy após Holm. LR permanece atrativa sob restrição forte de armazenamento/inferência (H3).

A interpretação deve incorporar as restrições do desenho experimental (riscos aceitos AR-1–AR-5). Em particular: BA e F1 macro com $C=21$ incluem zeros por ausência de classe no teste; a seleção por validação ocorreu em classes disjuntas do teste; orçamentos de busca desiguais limitam atribuições à “família algorítmica”; semente única e $n=11$ limitam o poder dos contrastes Wilcoxon.

Importâncias de atributos, quando analisadas em trabalhos derivados, devem permanecer descritivas do comportamento do modelo — nunca evidência causal do processo físico do TEP.

8 Ameaças à validade

8.1 Validade interna

Mitigadas: disjunção de run_id; seleção sem consulta ao teste; fit de transformações só no treino; protocolo único. **Não mitigada estruturalmente**: cobertura disjunta de classes entre validação e teste. O scorer de seleção por acurácia

amostral na validação está desalinhado com F1/BA sob desbalanceamento e sob o descompasso de classes.

8.2 Validade estatística

Rankings e critérios §4 usam métricas globais do holdout; testes Friedman/Wilcoxon [11, 12] agregam por `run_id` ($n=11$) antes da inferência (INV-09). Holm corrige famílias planejadas H1/H2. Poder limitado por n pequeno e semente única. Orçamentos de busca desiguais reduzem a comparabilidade entre famílias. A redação evita conclusões por métrica única.

8.3 Validade de constructo

Não interpretamos importância de atributos como física do TEP. Custo é sempre discutido junto ao desempenho. O constructo “macro sobre 21 classes” inclui zeros por ausência — documentado; o heatmap A6 usa NaN onde `support=0`.

8.4 Validade externa

Resultados em TEP simulado não generalizam automaticamente a plantas reais; o escopo é deliberadamente o TEP como referência. O estudo cobre apenas métodos clássicos e uma baseline de busca reduzida — não o máximo de cada família sob tuning ampliado.

8.5 Reprodutibilidade (transversal)

Manifesto, semente, snapshot de ambiente, predições e métricas estão versionados. Residual: `git_dirty: true` no snapshot A4; artefatos posteriores devem permanecer rastreáveis em histórico de commits.

8.6 Riscos metodológicos aceitos (ACCEPTED RISK)

Os riscos abaixo **não** podem ser eliminados sem novo desenho experimental (mais runs/classe, novo scorer, grids equalizados ou multi-semente) e, portanto, são **aceitos** para `exp-a4-v2`, com mitigação documental e risco residual explícito:

- **AR-1 (MAJOR-02).** Classes de validação e teste disjuntas. *Mitigação:* manifesto A3 documenta a limitação; seleção não usa o teste (INV-05); interpretação de hiperparâmetros restrita. *Residual:* configs escolhidas na validação não foram otimizadas nas falhas do teste.
- **AR-2 (MAJOR-03).** Scorer de seleção = acurácia amostral. *Mitigação:* rankings e H usam F1/MCC/custo (INV-06/07); ameaça nomeada. *Residual:* desalinhamento seleção ↔ métricas de publicação.
- **AR-3 (MAJOR-04).** Orçamentos de busca desiguais (GB 2 vs XGB 8; SVM linear). *Mitigação:* sem afirmação de esforço de otimização igual; baseline documentada em `exp-a4-v2.yaml`. *Residual:* diferenças entre famílias misturam algoritmo e budget.
- **AR-4 (MINOR-03).** F1/BA com $C=21$ e ~ 10 classes ausentes no teste. *Mitigação:* zeros documentados; heatmap com NaN; comparação só intra-holdout. *Residual:* macro não representa as 21 falhas industrialmente.

- **AR-5 (MINOR-04).** Semente única e $n=11$ runs. *Mitigação:* SPEC-008 declara unidade/ n ; H2 run-level reportada como não corroborada. *Residual:* baixo poder; sensibilidade a seed não quantificada.

9 Conclusões

Apresentamos um benchmark reproduzível de seis classificadores clássicos para diagnóstico multiclasse no TEP, com divisão por execução, isolamento do teste e avaliação multicritério. No experimento exp-a4-v2: RF/XGB/GB lideram; LR e SVM linear ficam atrás; XGBoost lidera acurácia enquanto RF lidera F1/MCC; falhas 3, 15 e 10 são as mais difíceis entre as presentes; XGBoost oferece o melhor compromisso observacional desempenho/custo. H1-H4 são *corroboradas* em §4; em run-level, H1 é corroborada e H2 não (Wilcoxon+Holm, run_accuracy, $n=11$).

As conclusões de ranking e de hipóteses devem ser lidas sob os **riscos aceitos** AR-1-AR-5 (Seção 8): cobertura disjunta val/teste, scorer de acurácia na seleção, grids desiguais, macro com classes ausentes e poder limitado ($n=11$, semente única). Nenhum desses riscos foi ocultado; nenhum foi “resolvido” alterando o protocolo congelado.

Trabalhos futuros incluem: (i) dataset canônico com mais runs por classe e splits com overlap controlado de classes entre val/teste; (ii) replicação multi-semente para aumentar o poder dos contrastes Wilcoxon (H2 permanece não significativa com $n=11$); (iii) tuning documentado com novo identificador de experimento; (iv) uso deste protocolo como referência clássica para modelos profundos, físico-informados e detecção precoce.

10 Referências

- [1] Leo H. Chiang, Evan L. Russell, and Richard D. Braatz. *Fault Detection and Diagnosis in Industrial Systems*. London: Springer, 2001.
- [2] Shen Yin et al. “A comparison study of basic data-driven fault diagnosis and process monitoring methods on the benchmark Tennessee Eastman process”. In: *Journal of Process Control* 22.9 (2012), pp. 1567–1581. DOI: [10.1016/j.jprocont.2012.06.009](https://doi.org/10.1016/j.jprocont.2012.06.009).
- [3] James J. Downs and Ernest F. Vogel. “A plant-wide industrial process control problem”. In: *Computers & Chemical Engineering* 17.3 (1993), pp. 245–255. DOI: [10.1016/0098-1354\(93\)80018-1](https://doi.org/10.1016/0098-1354(93)80018-1).
- [4] Evan L. Russell, Leo H. Chiang, and Richard D. Braatz. “Fault detection in industrial processes using canonical variate analysis and dynamic principal component analysis”. In: *Chemometrics and Intelligent Laboratory Systems* 51.1 (2000), pp. 81–93. DOI: [10.1016/S0169-7439\(00\)00058-1](https://doi.org/10.1016/S0169-7439(00)00058-1).
- [5] B. W. Matthews. “Comparison of the predicted and observed secondary structure of T4 phage lysozyme”. In: *Biochimica et Biophysica Acta (BBA) - Protein Structure* 405.2 (1975), pp. 442–451. DOI: [10.1016/0005-2795\(75\)90109-9](https://doi.org/10.1016/0005-2795(75)90109-9).
- [6] Cory A. Rieth et al. “Additional Tennessee Eastman Process Simulation Dataset for Anomaly Detection Evaluation”. In: *Harvard Dataverse* (2017). Dataset. DOI: [10.7910/DVN/6C3JR1](https://doi.org/10.7910/DVN/6C3JR1).

- [7] Leo Breiman. “Random Forests”. In: *Machine Learning* 45.1 (2001), pp. 5–32. DOI: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- [8] Tianqi Chen and Carlos Guestrin. “XGBoost: A Scalable Tree Boosting System”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 785–794. DOI: [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785).
- [9] Corinna Cortes and Vladimir Vapnik. “Support-Vector Networks”. In: *Machine Learning* 20.3 (1995), pp. 273–297. DOI: [10.1007/BF00994018](https://doi.org/10.1007/BF00994018).
- [10] Fabian Pedregosa et al. “Scikit-learn: Machine Learning in Python”. In: *Journal of Machine Learning Research* 12 (2011), pp. 2825–2830.
- [11] Milton Friedman. “The Use of Ranks to Avoid the Assumption of Normality Implicit in the Analysis of Variance”. In: *Journal of the American Statistical Association* 32.200 (1937), pp. 675–701.
- [12] Frank Wilcoxon. “Individual Comparisons by Ranking Methods”. In: *Biometrics Bulletin* 1.6 (1945), pp. 80–83.

Apêndice A — Índice de artefatos

Conteúdo	Caminho
Configuração	configs/experiments/exp-a4-v2.yaml
Snapshot A4	results/metadata/exp-a4-v2__config_snapshot.json
Métricas A5	results/tables/A5_exp-a4-v2__global_metrics.csv
Custo A5	results/tables/A5_exp-a4-v2__cost_metrics.csv
Por classe	results/tables/A5_exp-a4-v2__per_class_metrics.csv
QP3	results/tables/A5_exp-a4-v2__qp3_confused_faults.json
Friedman SPEC-008	results/tables/A8_exp-a4-v2__friedman.json
Wilcoxon H1/H2	results/tables/A8_exp-a4-v2__wilcoxon_H*_family.csv
Bundle estatístico	results/metrics/A8_exp-a4-v2__statistics.json
Relatório A7	reports/technical/A7_technical_report.md
Figuras A6	article/figures/A6_exp-a4-v2__*

Apêndice B — Critérios de aceite (manuscrito)

CA-07 (QP1-QP5), CA-08 (H1-H4) e CA-10 (estrutura de 10 seções + ameaças nas quatro categorias) são endereçados neste documento. Números alinhados a A5/A6/A8 estatístico (DOC-R03). Relatório operacional expandido: Entrega A7.