

Pontifícia Universidade Católica de Goiás

Programa de Pós-Graduação

Disciplina MEI0028 – Modelagem e Simulação

WP1A – Benchmark Reprodutível de Métodos Clássicos de Aprendizado de Máquina para Diagnóstico de Falhas Industriais

Subprojeto do Programa de Pesquisa

Diagnóstico Inteligente de Falhas em Sistemas Dinâmicos Industriais

Professor responsável: Clarimar José Coelho

Grupo: Grupo A

Base experimental: Tennessee Eastman Process

Produto científico previsto: artigo para periódico técnico-científico

Goiânia

2026

Sumário

1	Identificação do subprojeto	3
2	Contextualização	3
3	Problema de pesquisa	3
4	Questões de pesquisa	4
5	Hipóteses	4
6	Objetivos	4
6.1	Objetivo geral	4
6.2	Objetivos específicos	5
7	Base de dados	5
8	Modelos avaliados	6
9	Protocolo experimental	6
9.1	Etapa 1 – Auditoria dos dados	6
9.2	Etapa 2 – Análise exploratória	7
9.3	Etapa 3 – Divisão experimental	7
9.4	Etapa 4 – Pré-processamento	7
9.5	Etapa 5 – Treinamento e seleção	7
9.6	Etapa 6 – Avaliação final	7
10	Métricas	8
11	Análise estatística	8
12	Insumos para o artigo	9
13	Estrutura sugerida do artigo	9
14	Título provisório do artigo	10
15	Entregas do grupo	10

16 Cronograma sugerido	10
17 Critérios de avaliação acadêmica	11
18 Riscos e cuidados metodológicos	11
19 Resultados esperados	11
20 Estrutura mínima do repositório	12
21 Considerações finais	12

1 Identificação do subprojeto

Título	Benchmark reproduzível de métodos clássicos de aprendizado de máquina para diagnóstico de falhas no Tennessee Eastman Process.
Código	WP1A.
Disciplina	MEI0028 – Modelagem e Simulação.
Grupo responsável	Grupo A.
Natureza	Projeto aplicado de modelagem, simulação, análise de dados e inteligência artificial.
Produto principal	Artigo científico de base metodológica.

2 Contextualização

Sistemas industriais modernos são compostos por variáveis fortemente acopladas, comportamento dinâmico, perturbações operacionais e múltiplos modos de falha. Nesse contexto, o diagnóstico automático de falhas constitui uma tarefa de classificação multiclasse na qual se pretende distinguir a condição normal de diferentes anomalias de processo. O Tennessee Eastman Process (TEP) é amplamente utilizado como ambiente de referência para estudos de monitoramento e diagnóstico por representar, de forma simulada, um processo químico multivariado, não linear e sujeito a falhas de diferentes naturezas.

Este subprojeto propõe a construção de um benchmark reproduzível de métodos clássicos de aprendizado de máquina. O foco não será apenas identificar o algoritmo com maior acurácia, mas comparar desempenho preditivo, equilíbrio entre classes, robustez, custo computacional, interpretabilidade e viabilidade de aplicação em sistemas industriais.

O estudo integra conteúdos da disciplina de Modelagem e Simulação ao tratar o processo industrial como um sistema dinâmico observado por variáveis de estado e de operação. Os modelos de classificação serão avaliados como mecanismos computacionais de diagnóstico construídos a partir das respostas simuladas do sistema sob condições normais e de falha.

3 Problema de pesquisa

Dado um conjunto de dados multivariado proveniente da simulação do Tennessee Eastman Process, qual método clássico de aprendizado de máquina apresenta o melhor compromisso

entre capacidade de classificação, equilíbrio entre classes, custo computacional, estabilidade e interpretabilidade no diagnóstico de falhas industriais?

4 Questões de pesquisa

- QP1:** Quais algoritmos clássicos apresentam o melhor desempenho global na classificação das condições operacionais do TEP?
- QP2:** O desempenho global é consistente quando se considera o equilíbrio entre as 21 classes?
- QP3:** Quais falhas são sistematicamente mais difíceis de diagnosticar?
- QP4:** Métodos mais complexos produzem ganhos suficientes para justificar maior custo computacional?
- QP5:** Qual modelo apresenta o melhor compromisso entre desempenho, tempo de treinamento, tempo de inferência e tamanho do arquivo treinado?

5 Hipóteses

- H1:** Métodos de conjunto baseados em árvores apresentam desempenho superior aos classificadores lineares em razão das relações não lineares entre as variáveis do processo.
- H2:** XGBoost e Random Forest apresentam maior F1 macro e MCC do que Regressão Logística e Árvore de Decisão isolada.
- H3:** A Regressão Logística permanece competitiva em custo computacional e interpretabilidade, embora apresente menor capacidade de separar falhas com padrões sobrepostos.
- H4:** O melhor modelo segundo acurácia não necessariamente será o melhor quando considerados F1 macro, MCC e custo de inferência.

6 Objetivos

6.1 Objetivo geral

Desenvolver e avaliar um benchmark reproduzível de algoritmos clássicos de aprendizado de máquina para diagnóstico multiclasse de falhas no Tennessee Eastman Process.

6.2 Objetivos específicos

1. Auditar e documentar a base de dados utilizada no estudo.
2. Aplicar um protocolo único de divisão entre treinamento, validação e teste, evitando vazamento entre execuções do processo.
3. Treinar Regressão Logística, Árvore de Decisão, Random Forest, Gradient Boosting, SVM e XGBoost.
4. Avaliar os modelos por métricas globais e específicas por classe.
5. Comparar tempos de treinamento, tempos de inferência e tamanho dos modelos.
6. Identificar falhas com maior grau de confusão.
7. Produzir tabelas, figuras, arquivos de resultados e documentação reproduzível.
8. Elaborar um artigo científico com os resultados do benchmark.

7 Base de dados

O experimento utilizará os dados do Tennessee Eastman Process disponibilizados em arquivos de treinamento e teste, contendo execuções sem falha e execuções com falhas induzidas. A versão atualmente empregada no laboratório contém 52 variáveis de processo e 21 classes, considerando a condição normal e 20 condições de falha.

A unidade independente de divisão dos dados deverá ser a execução do processo, denominada *run*. Amostras pertencentes à mesma execução não poderão aparecer simultaneamente nos conjuntos de treinamento e teste. Essa restrição é essencial para impedir vazamento de informação temporal e superestimação do desempenho.

8 Modelos avaliados

Tabela 1: Algoritmos integrantes do benchmark WP1A.

Modelo	Papel no benchmark
Regressão Logística	Baseline linear, interpretável e de baixo custo computacional.
Árvore de Decisão	Modelo não linear simples, com regras diretamente interpretáveis.
Random Forest	Método de conjunto com redução de variância e boa robustez.
Gradient Boosting	Referência de boosting sequencial com árvores rasas.
SVM	Classificador de margem máxima; será usada inicialmente uma implementação escalável.
XGBoost	Baseline forte de boosting otimizado e regularizado.

9 Protocolo experimental

9.1 Etapa 1 – Auditoria dos dados

A auditoria deverá verificar:

- arquivos disponíveis;
- quantidade de linhas e colunas;
- nomes, tipos e significado das variáveis;
- distribuição das classes;
- quantidade de execuções por classe;
- valores ausentes, infinitos ou inconsistentes;
- possíveis duplicações;
- relação entre arquivos, classes e identificadores de execução.

9.2 Etapa 2 – Análise exploratória

A análise exploratória incluirá estatísticas descritivas, distribuição das classes, variabilidade das variáveis, correlações, projeções por PCA e inspeção de possíveis diferenças entre o regime normal e os regimes de falha.

9.3 Etapa 3 – Divisão experimental

A divisão deverá ser realizada por execução completa. O protocolo-base será:

- treinamento: execuções destinadas ao ajuste dos modelos;
- validação: execuções independentes para seleção de hiperparâmetros;
- teste: execuções nunca usadas durante o desenvolvimento.

A semente aleatória, a lista de execuções e o manifesto de divisão deverão ser salvos para garantir repetibilidade.

9.4 Etapa 4 – Pré-processamento

O pipeline principal utilizará as decisões já estabelecidas na infraestrutura comum do projeto. Transformações dependentes dos dados, como padronização, serão ajustadas exclusivamente no conjunto de treinamento e aplicadas aos conjuntos de validação e teste.

9.5 Etapa 5 – Treinamento e seleção

Cada algoritmo deverá ser treinado sob condições documentadas. A seleção de hiperparâmetros deverá usar apenas o conjunto de validação ou validação cruzada interna aplicada ao conjunto de treinamento. O conjunto de teste será consultado somente após o congelamento da configuração final.

9.6 Etapa 6 – Avaliação final

Seja C o número de classes. Para cada classe c , serão calculadas precisão, revocação e F1. A F1 macro será definida por

$$F1_{macro} = \frac{1}{C} \sum_{c=1}^C F1_c. \quad (1)$$

A acurácia balanceada será

$$BA = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c}. \quad (2)$$

Também será utilizado o coeficiente de correlação de Matthews multiclasse (MCC), por fornecer uma avaliação mais informativa quando existem erros distribuídos entre várias classes.

10 Métricas

- acurácia;
- acurácia balanceada;
- precisão macro;
- revocação macro;
- F1 macro;
- F1 ponderada;
- MCC multiclasse;
- matriz de confusão;
- métricas por classe;
- tempo de treinamento;
- tempo de inferência;
- tamanho do modelo salvo;
- consumo de memória, quando disponível.

11 Análise estatística

Sempre que houver resultados provenientes de múltiplas execuções independentes, sementes ou partições, deverão ser reportados média, desvio-padrão e intervalo de confiança. A comparação estatística poderá utilizar o teste de Friedman seguido por procedimento pós-hoc apropriado. Comparações pareadas específicas poderão utilizar Wilcoxon com correção para múltiplas comparações.

A unidade experimental deve ser explicitada. Não se deve tratar cada linha temporal correlacionada como repetição estatisticamente independente.

12 Insumos para o artigo

O grupo deverá gerar, no mínimo:

1. tabela de caracterização da base;
2. tabela dos hiperparâmetros dos modelos;
3. tabela comparativa das métricas globais;
4. tabela de métricas por classe;
5. matrizes de confusão;
6. gráfico comparativo de F1 macro e MCC;
7. gráfico de custo computacional;
8. análise das falhas mais confundidas;
9. arquivos CSV com resultados brutos;
10. metadados do ambiente computacional;
11. repositório com scripts numerados e instruções de execução.

13 Estrutura sugerida do artigo

1. Introdução;
2. Fundamentação sobre diagnóstico de falhas e TEP;
3. Trabalhos relacionados;
4. Materiais e métodos;
5. Protocolo reproduzível;
6. Resultados;
7. Discussão;
8. Ameaças à validade;
9. Conclusões;
10. Referências.

14 Título provisório do artigo

Benchmark reproduzível de métodos clássicos de aprendizado de máquina para diagnóstico de falhas no Tennessee Eastman Process

Título provisório em inglês:

A Reproducible Benchmark of Classical Machine Learning Methods for Fault Diagnosis in the Tennessee Eastman Process

15 Entregas do grupo

Tabela 2: Entregas previstas para o WP1A.

ID	Entrega	Formato
A1	Relatório de auditoria da base	PDF/CSV
A2	Análise exploratória	Notebook/figuras
A3	Manifesto da divisão por execução	CSV/JSON
A4	Implementação dos seis modelos	Python
A5	Resultados completos	CSV/JSON
A6	Figuras e tabelas do artigo	PNG/PDF/LaTeX
A7	Relatório técnico final	PDF
A8	Manuscrito científico	LaTeX/Word
A9	Apresentação do projeto	PDF/PPTX

16 Cronograma sugerido

Tabela 3: Cronograma acadêmico sugerido para o WP1A.

Atividade	1	2	3	4	5	6	7	8
Revisão e auditoria	X	X						
EDA e preparação		X	X					
Treinamento dos modelos			X	X	X			
Avaliação e estatística					X	X		
Geração de figuras e tabelas						X	X	
Redação do artigo				X	X	X	X	X
Apresentação final								X

17 Critérios de avaliação acadêmica

Tabela 4: Critérios de avaliação do Grupo A.

Critério	Peso
Correção metodológica e prevenção de vazamento	20%
Qualidade da implementação e reprodutibilidade	20%
Análise dos resultados	20%
Qualidade das figuras, tabelas e documentação	15%
Relatório e manuscrito científico	15%
Apresentação e domínio do tema	10%
Total	100%

18 Riscos e cuidados metodológicos

- vazamento de dados entre execuções;
- ajuste de hiperparâmetros com base no teste;
- comparação injusta entre modelos;
- uso exclusivo de acurácia;
- omissão de custo computacional;
- inferência estatística baseada em amostras temporalmente correlacionadas;
- interpretação causal indevida de importâncias de atributos;
- falta de registro das versões de software e sementes aleatórias.

19 Resultados esperados

Espera-se obter um panorama confiável do comportamento de seis famílias clássicas de aprendizado de máquina no diagnóstico de falhas do TEP. O estudo deverá identificar o melhor modelo global, os melhores modelos sob restrições de custo e interpretabilidade e as classes de falha que permanecem difíceis de separar. O artigo resultante constituirá a referência clássica para comparações posteriores com modelos profundos, métodos orientados pela física e estratégias de detecção precoce.

20 Estrutura mínima do repositório

```
ProjetoA_WP1A/  
|-- data/  
| |-- raw/  
| |-- processed/  
|-- src/  
|-- configs/  
|-- models/  
|-- results/  
| |-- tables/  
| |-- figures/  
| |-- predictions/  
| |-- metadata/  
|-- reports/  
|-- article/  
|-- README.md  
|-- requirements.txt
```

21 Considerações finais

O WP1A deverá ser conduzido como um benchmark científico e não apenas como uma atividade de treinamento de classificadores. Todas as decisões devem ser rastreáveis e justificadas. O principal produto do grupo será um protocolo reproduzível capaz de sustentar a comparação entre modelos clássicos e servir de referência para os demais projetos da linha de pesquisa.

Referências

- [1] DOWNS, J. J.; VOGEL, E. F. A plant-wide industrial process control problem. *Computers & Chemical Engineering*, v. 17, n. 3, p. 245–255, 1993.
- [2] CHIANG, L. H.; RUSSELL, E. L.; BRAATZ, R. D. *Fault Detection and Diagnosis in Industrial Systems*. London: Springer, 2001.
- [3] BREIMAN, L. Random forests. *Machine Learning*, v. 45, p. 5–32, 2001.
- [4] FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. *The Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001.

- [5] CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016. p. 785–794.