

Grupo A — WP1A / MEI0028 — Modelagem e Simulação
Pontifícia Universidade Católica de Goiás

Experimento oficial: exp-a4-v2 | 2026-09-14

Números citados $\leftrightarrow$ results/ (DOC-R03). Sem causalidade física (INV-08).
Sem “melhor modelo” por acurácia só (INV-06).

- 1 Problema e objetivos
- 2 Protocolo
- 3 Resultados
- 4 Ameaças e conclusões

- Diagnóstico multiclasse de falhas no **Tennessee Eastman Process** (TEP): 52 variáveis, 21 classes (1 normal + 20 falhas).
- Estudos comparativos costumam misturar protocolos, vaziar informação temporal entre partições e eleger “vencedor” só por acurácia.
- **WP1A:** benchmark *reproduzível* de 6 famílias clássicas sob protocolo único, multicritério (desempenho + custo).

Objetivo geral

Comparar Regressão Logística, Árvore, Random Forest, Gradient Boosting, SVM e XGBoost sem vazamento por execução (run), isolando o teste até o congelamento das configurações.

- QP1** Quais algoritmos têm melhor desempenho *global*?
- QP2** O ranking é consistente sob equilíbrio entre classes (Acc vs BA/F1/MCC)?
- QP3** Quais falhas são sistematicamente mais difíceis?
- QP4** Complexidade justifica maior custo computacional?
- QP5** Qual o melhor *compromisso* desempenho $\times$ tempo $\times$ tamanho?

- H1 Ensembles em árvore $>$ Regressão Logística (F1 e/ou MCC).
- H2 XGBoost e RF $>$ LR e árvore isolada (F1 e MCC).
- H3 LR competitiva em custo; F1 reduzido nas falhas difíceis.
- H4 Melhor por acurácia $\neq$ melhor por F1 / MCC / custo de inferência.

Critérios binários SPEC-000 §4: *corroborada / refutada*. Evidência em dois planos: holdout global + testes SPEC-008 por run.

- Unidade = **execução** (run_id), nunca a amostra (UE-01).
- Partições com interseção vazia de runs (INV-01/02).
- Scaler fit só no treino (INV-04).
- Teste consultado **uma vez**, após freeze (INV-05).
- Mesmo manifesto + preprocessor para os 6 modelos (INV-03).

Pipeline

Audit → EDA → Split
→ Preprocess → Train
→ Eval → Stats
→ Figures → Report

Experimento: exp-a4-v2

Semente: 42

Dataset: tep-canonical-v1


Item	Valor
Features	52
Classes	21
Runs	42
Linhas	30 260

Fonte: A6 dataset

summary.

- Treino: 21 runs
Val: 10 Teste: 11
- **Limitação (AR-1):** com 2 runs/classe, classes de val e teste são *disjuntas*.
- Scorer de seleção = acurácia na val (AR-2).
- Grids desiguais nesta baseline (AR-3).

Fonte: A5_exp-a4-v2__global_metrics.csv. Macro com $C=21$ inclui classes ausentes no teste (AR-4).



A6 — Custo computacional (INV-07)




Figura A6 — custo (treino, inferência, tamanho). INV-07.

- QP1 Grupo superior: RF, XGB, GB; inferior: LR, SVM linear.
- QP2 Ranking Acc (XGB→RF) $\neq$ BA/F1/MCC (RF→XGB).
- QP3 Classes presentes mais difíceis: **3, 15, 10**; confusões 10→15 e 3→15 (sem causalidade física).
- QP4 GB (treino ≈ 282 s) não supera RF/XGB; SVM linear caro e fraco.
- QP5 RF (F1/MCC); XGB (compromisso); DT (custo mínimo) — sem vencedor único.

- Unidade = run_id; $n=11$ runs de teste; métrica = run_accuracy.
- **Friedman:** $\chi^2=14,08$, $p=0,015$ — rejeita igualdade global.
- **Wilcoxon + Holm** (famílias planejadas):
 - H1 (3 pares vs LR): **corroborada** em run-level.
 - H2 (4 pares vs LR/DT): **não corroborada** (nenhum par após Holm; AR-5).

Dois planos de evidência

§4 (F1/MCC/custo globais) e SPEC-008 (run_accuracy). Concordância não é automática.

- H4: líderes distintos — XGB (Acc), RF (F1/MCC), DT (inferência).
- Sem interpretação causal de atributos (INV-08).

- **AR-1** Classes val $\cap$ teste = $\emptyset$ (2 runs/classe).
- **AR-2** Scorer de seleção = acurácia amostral.
- **AR-3** Orçamentos de busca desiguais; SVM só linear.
- **AR-4** Macro $C=21$ com ~ 10 classes ausentes no teste.
- **AR-5** Semente única; $n=11$ (baixo poder).

Formalizados na revisão A8_scientific_review_exp-a4-v3_post_remediation.md:
APPROVE WITH ACCEPTED RISKS. Protocolo congelado — remoção exige novo experiment_id.

- 1 Benchmark ponta a ponta com anti-vazamento por run e avaliação multicritério.
- 2 RF/XGB/GB lideram; LR e SVM linear atrás; **não** há único melhor modelo.
- 3 H1-H4 *corroboradas* em §4; H1 também em run-level; H2 não (poder / família Holm).
- 4 Compromisso observacional: **XGBoost**; pico F1/MCC: **RF**; custo mínimo: **DT**.
- 5 Referência clássica para trabalhos futuros (profundos, físico-informados, detecção precoce), sob AR-1-AR-5.

- A5 métricas: results/tables/A5_exp-a4-v2__*
- A6 figuras: article/figures/A6_exp-a4-v2__*
- SPEC-008: results/tables/A8_exp-a4-v2__* /
results/metrics/A8_exp-a4-v2__statistics.json
- A7: reports/technical/A7_technical_report.pdf
- A8: article/manuscript/manuscript.pdf
- Revisão: A8_scientific_review_exp-a4-v3_post_remediation.md

Obrigado

Grupo A — WP1A / MEI0028