

Contents

Relatório técnico final (Entrega A7)	1
Sumário executivo	2
1. Introdução	3
1.1 Problema	3
1.2 Objetivos do WP1A	3
1.3 Questões de pesquisa e hipóteses	3
2. Fundamentação: diagnóstico de falhas e TEP	3
3. Trabalhos relacionados (posicionamento)	4
4. Materiais e métodos	4
4.1 Dataset canônico	4
4.2 Análise exploratória (Etapa 2 / A2)	4
4.3 Divisão agrupada por execução (Etapa 3 / A3)	4
4.4 Pré-processamento (Etapa 4)	5
4.5 Modelos (MOD-1 a MOD-6)	5
4.6 Seleção de hiperparâmetros (Etapa 5 / A4)	5
4.7 Avaliação (Etapa 6 / A5)	6
4.8 Ambiente computacional	6
5. Protocolo reproduzível	6
6. Resultados	7
6.1 Métricas globais e custo (teste)	7
6.2 Métricas por classe e confusões	8
6.3 Respostas explícitas a QP1–QP5	8
6.4 Análise estatística formal (SPEC-008)	9
7. Avaliação das hipóteses (H1–H4)	10
H1 — Conjuntos em árvore superam regressão logística (F1 e/ou MCC)	10
H2 — XGBoost e Random Forest > LR e árvore isolada (F1 e MCC)	10
H3 — LR competitiva em custo; F1 reduzido nas falhas difíceis (QP3)	11
H4 — Melhor por acurácia ≠ melhor por F1 / MCC / custo de inferência	11
8. Discussão	11
9. Ameaças à validade	12
9.1 Validade interna	12
9.2 Validade estatística	12
9.3 Validade de constructo	13
9.4 Validade externa	13
9.5 Reprodutibilidade (transversal)	13
9.6 Riscos metodológicos aceitos (ACCEPTED RISK)	14
10. Conclusões	14
11. Índice de artefatos (rastreadabilidade DOC-R03)	15
12. Referências normativas e bibliográficas mínimas	15
Apêndice A — Checklist de aceite tocado por A7	16

Relatório técnico final (Entrega A7)

Título: Benchmark reproduzível de métodos clássicos de aprendizado de máquina para diagnóstico de falhas no Tennessee Eastman Process

Campo	Valor
Entrega	A7 — Relatório técnico final (SPEC-000 §11.1; SPEC-009 §3.2)
Subprojeto	WP1A / MEI0028 - Modelagem e Simulação
Experimento oficial	exp-a4-v2 (baseline SPEC-006 / A4 + avaliação SPEC-007 / A5)
Dataset canônico	tep-canonical-v1
Manifesto de divisão	data/processed/split_manifest_v1.json (A3)
Pré-processamento	preprocessor_v1 (fit exclusivo no treino)
Semente	42 (configs/seeds.yaml)
SHA de execução A4	40c6c6026f39c6e356ed8e3e57950a7a89dddb5e (git_dirty: true no snapshot)
Data do relatório	2026-09-14
Fontes normativas	docs/specs/SPEC-000-master.md, AGENTS.md, SPEC-001...009

Escopo deste documento. Consolida metodologia, protocolo reproduzível, resultados e respostas a QP1-QP5 / H1-H4 com rastreabilidade a artefatos em results/ e article/ (DOC-R03). Inclui a análise estatística formal SPEC-008 (Friedman/Wilcoxon com unidade = run_id). Não interpreta importâncias de atributos como causalidade física do TEP (INV-08 / MET-R07).

Sumário executivo

Sob o protocolo compartilhado do experimento exp-a4-v2, os conjuntos baseados em árvores (Random Forest, XGBoost, Gradient Boosting) lideram as métricas globais de classificação no conjunto de teste; Regressão Logística e SVM linear formam o grupo inferior. O líder em acurácia simples (XGBoost) **não** coincide com o líder em F1 macro / MCC (Random Forest). Entre classes presentes no teste, as falhas **3, 15 e 10** apresentam os menores F1 médios; as confusões **10→15** e **3→15** são as mais frequentes. Multicritério: RF maximiza F1/MCC; XGBoost oferece compromisso desempenho/custo; Decision Tree é o extremo de custo baixo. Pelos critérios binários de SPEC-000 §4 (estimativas pontuais do holdout), H1-H4 são **corroboradas**. Em nível de run (SPEC-008, acurácia dentro da execução, n=11): Friedman rejeita igualdade global (p=0,015); Wilcoxon+Holm na família H1 **corrobora** ensembles > LR; a família H2 **não** corrobora RF/XGB > DT (poder limitado). Ameaças críticas: cobertura disjunta val/teste de classes; semente/split únicos; orçamentos de busca desiguais.

1. Introdução

1.1 Problema

O diagnóstico automático de falhas em processos químicos industriais exige classificadores capazes de distinguir a condição normal de múltiplos modos de falha a partir de variáveis de processo. O Tennessee Eastman Process (TEP) é um ambiente simulado de referência com 52 variáveis e 21 classes (1 normal + 20 falhas). Comparações entre algoritmos frequentemente sofrem de vazamento temporal entre partições, protocolos inconsistentes entre modelos e conclusões baseadas apenas em acurácia simples.

1.2 Objetivos do WP1A

Conforme SPEC-000 §1, o subprojeto desenvolve um **benchmark reproduzível** de seis famílias clássicas de aprendizado de máquina, avaliando desempenho preditivo, equilíbrio entre classes, custo computacional e interpretabilidade descritiva — sem pretender estado da arte em modelos profundos ou física-orientada (SPEC-000 §2.2).

Objetivos específicos OBJ-1 a OBJ-8 (auditoria → artigo) estruturam as entregas A1–A9. Este relatório (A7) responde às questões de pesquisa QP1–QP5 e avalia as hipóteses H1–H4 com evidência do conjunto de teste do experimento congelado exp-a4-v2.

1.3 Questões de pesquisa e hipóteses

ID	Conteúdo (SPEC-000 §§3–4)
QP1	Melhor desempenho global entre os 6 algoritmos
QP2	Consistência sob equilíbrio entre classes (acurácia vs BA/F1/MCC)
QP3	Falhas sistematicamente mais difíceis
QP4	Complexidade vs justificativa de custo
QP5	Melhor compromisso desempenho × tempo × tamanho
H1–H4	Ver Seção 7 deste relatório

2. Fundamentação: diagnóstico de falhas e TEP

O TEP simula uma planta química com reciclo, reator, condensador, separador e stripper. Cada execução (*run*) induz (ou não) uma falha e produz uma série temporal de observações. No WP1A, o problema é formulado como **classificação multiclasse** de vetores de 52 variáveis para um rótulo em $\{0, \dots, 20\}$.

A **unidade experimental** é a execução (*run_id*), não a linha/amostra (UE-01). Observações dentro de um mesmo run são temporalmente correlacionadas; tratá-las como independentes viola INV-09. A divisão treino/validação/teste e **toda** inferência estatística (incluindo SPEC-008) devem respeitar essa unidade (UE-02, UE-03).

3. Trabalhos relacionados (posicionamento)

Este relatório não reproduz uma revisão bibliográfica exaustiva (reservada ao manuscrito A8). Em síntese, o posicionamento do WP1A é:

1. **Protocolo único** para seis classificadores clássicos (INV-03), em contraste com estudos que misturam splits ou pré-processamentos por modelo.
2. **Anti-vazamento por run** como invariante operacional (INV-01/INV-02), com checagem automatizada no manifesto A3.
3. **Avaliação multicritério** obrigatória (INV-06, INV-07; ADR-007), incluindo custo (MET-10-12).
4. **Delimitação explícita** frente a redes profundas e métodos físico-informados, que usam este benchmark como referência clássica futura (SPEC-000 §2.2).

4. Materiais e métodos

4.1 Dataset canônico

Item	Valor	Fonte
Versão	tep-canonical-v1	article/tables/A6_exp-a4-v2__01_dataset_summary.csv
Features	52	idem
Classes canônicas	21	idem
Runs canônicos	42	idem
Linhas	30 260	idem
Pacote bruto auditado	44 arquivos; 22 classes observadas no pack	A1 / sumário A6

A auditoria (Etapa 1 / A1) e o registro canônico (SPEC-002) precedem qualquer modelagem. Detalhes operacionais: reports/audit/, data/processed/canonical_dataset_registry.

4.2 Análise exploratória (Etapa 2 / A2)

A EDA documenta distribuições e correlações **sem** decidir hiperparâmetros nem o manifesto de divisão científica. Artefatos: reports/eda/, results/figures/A2_*.png, results/tables/A2_*.csv.

4.3 Divisão agrupada por execução (Etapa 3 / A3)

- **Manifesto:** data/processed/split_manifest_v1.json
- **Estratégia:** stratified_one_train_per_class_remaining_split_val_test — um run por classe no treino; restante ~50/50 validação/teste (semente 42).
- **Partições:** treino 21 runs; validação 10; teste 11.
- **Checagem de leakage:** leakage_check.status = passed (interseção vazia de run_id par a par).

Limitação estrutural documentada no manifesto: com apenas dois runs por classe no canônico, reservar um run/classe ao treino implica que validação e teste **não cobrem simultaneamente as 21 classes**. Em exp-a4-v2:

Partição	Classes presentes	Classes ausentes
Validação	0, 1, 4, 5, 7, 8, 9, 12, 16, 17	2, 3, 6, 10, 11, 13, 14, 15, 18, 19, 20
Teste	2, 3, 6, 10, 11, 13, 14, 15, 18, 19, 20	0, 1, 4, 5, 7, 8, 9, 12, 16, 17

Os conjuntos de classes de validação e teste são **disjuntos**. Isso afeta a validade de constructo da seleção por validação (ver Seção 8).

4.4 Pré-processamento (Etapa 4)

Versão `preprocessor_v1`: padronização (e demais transformações dependentes dos dados) **ajustadas exclusivamente no treino** e aplicadas a validação/teste (INV-04 / LEAK-R02 / LEAK-R05). Artefatos: `preprocessor_v1_*.csv.gz`, `preprocessor_v1_scaler_params.json`, metadados em `results/metadata/preprocessing.json`.

4.5 Modelos (MOD-1 a MOD-6)

Código	Modelo	Adapter
MOD-1	Regressão logística	<code>logistic_regression</code>
MOD-2	Árvore de decisão	<code>decision_tree</code>
MOD-3	Random Forest	<code>random_forest</code>
MOD-4	Gradient Boosting (sklearn)	<code>gradient_boosting</code>
MOD-5	SVM	<code>svm</code>
MOD-6	XGBoost	<code>xgboost</code>

Todos passam pelo mesmo `ExperimentRunner` (`src/wp1a/experiment/`), mesmo manifesto A3 e mesmo `preprocessor_v1` (INV-03 / MET-R03).

4.6 Seleção de hiperparâmetros (Etapa 5 / A4)

- Configuração: `configs/experiments/exp-a4-v2.yaml`
- Seleção **somente** em treino/validação; teste consultado após congelamento (INV-05).
- Espaços de busca do **baseline reduzido** (não SPEC-006A):
 - GB: 2 candidatos (`n_estimators=50`, `max_depth` ∈ {2,3})
 - SVM: apenas `kernel: linear`
 - XGBoost: 8 candidatos; RF: 4; etc. (orçamentos **desiguais** — ameaça de validade estatística/comparabilidade)

- Scorer de seleção nesta rodada: acurácia na validação (limitação discutida na Seção 8, dado o descompasso de classes val↔teste).

Hiperparâmetros finais selecionados (article/tables/A6_exp-a4-v2__02_hyperparameters)

Modelo	Principais parâmetros
logistic_regression	C=10.0, max_iter=1000, solver=lbfgs
decision_tree	max_depth=20, min_samples_leaf=5, criterion=gini
random_forest	n_estimators=200, max_depth=20, min_samples_leaf=1
gradient_boosting	n_estimators=50, learning_rate=0.1, max_depth=3
svm	C=10.0, kernel=linear, cache_size=500
xgboost	n_estimators=100, learning_rate=0.1, max_depth=6, tree_method=hist

4.7 Avaliação (Etapa 6 / A5)

Métricas MET-01 a MET-12 conforme SPEC-000 §9; F1 macro e acurácia balanceada com **C = 21** (classes ausentes no teste entram com contribuição nula e deprimem BA/F1 em relação à acurácia). Verificação CA-06: formula_checks_ok=True nos seis modelos (results/tables/A5_exp-a4-v2__global_metrics.csv).

Figuras/tabelas A6 geradas **somente** a partir de results/ (proibido data/raw): make figures → article/figures|tables/A6_exp-a4-v2__*.

4.8 Ambiente computacional

Fonte: results/metadata/exp-a4-v2__config_snapshot.json.

Item	Valor
Python	3.12.7 (CPython)
scikit-learn	1.9.1
xgboost	2.1.4
numpy / pandas / joblib	1.26.4 / 2.2.3 / 1.4.2
Plataforma	Linux x86_64, 16 CPUs
Branch / SHA	feat/experiment-runner / 40c6c6026f39... (git_dirty: true)

5. Protocolo reprodutível

Requisito	Cumprimento neste experimento
REP-01 semente	42 registrada no manifesto e no snapshot

Requisito	Cumprimento neste experimento
REP-02 run_ids por partição	split_manifest_v1.json + CSVs train/validation/test_runs.csv
REP-03 versões de software	snapshot environment
REP-04 hiperparâmetros finais	A6 tabela 02 / results/tables/
REP-05 scripts e README	make train, make evaluate, make figures; README.md
REP-06 resultados brutos	results/predictions/, results/tables/A5_*, results/metrics/A5_*

Ordem fixa do pipeline (MET-R02): Auditoria → EDA → Divisão → Pré-processamento → Treinamento/Seleção → Avaliação final. O dry-run (make dry-run, scientific_validity: false) **não** alimenta este relatório.

Identidade do experimento: exp-a4-v2 substitui exp-a4-v1 (abortado no GB); novo experiment_id conforme EXP-R04. Tuning ampliado (SPEC-006A) **não** foi executado e não altera esta baseline.

Comandos de referência:

```
make audit && make canonical-dataset && make eda && make split && make preprocess
make train EXPERIMENT=exp-a4-v2 # ou configs/experiments/exp-a4-v2.yaml
make evaluate EXPERIMENT=exp-a4-v2
make figures EXPERIMENT=exp-a4-v2
```

6. Resultados

Todas as afirmações quantitativas citam arquivos versionados.

6.1 Métricas globais e custo (teste)

Fonte: results/tables/A5_exp-a4-v2__global_metrics.csv e ...__cost_metrics.csv.
Visualizações: article/figures/A6_exp-a4-v2__06_f1_mcc.png, ...__07_computational_cost.png; tabelas article/tables/A6_exp-a4-v2__03_global_metrics.*, ...__07_computational_cost.csv.

Modelo	Acc (MET-01)	BA (MET-02)	F1 macro (MET-05)	MCC (MET-07)	Treino s (MET-10)	Inferência s (MET-11)	Tamanho B (MET-12)
logistic_regression	0.575	0.164	0.184	0.250	3.65	0.0031	10 020
decision_tree	0.564	0.303	0.314	0.560	1.36	0.0015	158 662
random_forest	0.617	0.333	0.357	0.597	3.09	0.243	49 567 094
gradient_boosting	0.608	0.321	0.347	0.584	281.89	0.101	1 901 442
svm	0.237	0.150	0.163	0.215	177.03	3.575	8 782 836

Modelo	Acc (MET-01)	BA (MET-02)	F1 macro (MET-05)	MCC (MET-07)	Treino s (MET-10)	Inferência s (MET-11)	Tamanho B (MET-12)
xgboost	0.618	0.330	0.353	0.596	22.28	0.052	4 910 294

Valores arredondados; precisão completa nos CSVs citados. formula_checks_ok=True para todos.

6.2 Métricas por classe e confusões

- Por classe: results/tables/A5_exp-a4-v2__per_class_metrics.csv / article/tables/A6_exp-a4-v2__04_per_class_metrics.csv
- Matrizes: article/figures/A6_exp-a4-v2__05_cm__*.png
- Heatmap F1 (NaN onde support=0): article/figures/A6_exp-a4-v2__08_per_class_f1_heatmap.png
- Pares confundidos: article/tables/A6_exp-a4-v2__08_confused_pairs.csv, ...__08_confused_pairs.png, results/tables/A5_exp-a4-v2__qp3_confused_faults.json

Classes com support > 0 e menor F1 médio (6 modelos): 3 (0.184), 15 (0.252), 10 (0.283).

Pares mais frequentes (soma entre modelos): 10→15 (1451), 3→15 (1002), 18→5 (1001), 13→12 (809).

Classes com support = 0 no teste **não** são interpretadas como “falhas difíceis observadas” neste holdout (F1=0 por ausência).

6.3 Respostas explícitas a QP1-QP5

QP1 — Quais algoritmos apresentam o melhor desempenho global? Resposta. No teste de exp-a4-v2, o grupo superior em métricas globais é formado por **Random Forest, XGBoost e Gradient Boosting**, seguidos de Decision Tree; **Regressão Logística e SVM linear** ficam no grupo inferior (A5_exp-a4-v2__global_metrics.csv). Não há “melhor modelo” oficial por métrica única (INV-06): por acurácia lidera XGBoost (0.618); por F1 macro e MCC lidera Random Forest (0.357 / 0.597).

QP2 — O desempenho é consistente sob equilíbrio entre classes? Resposta. Não totalmente. Ranking por acurácia: XGB → RF → GB → DT → LR → SVM. Ranking por BA / F1 macro / MCC: **RF → XGB** → GB → DT → LR → SVM. A lacuna acurácia >> BA/F1 é compatível com a média sobre C=21 incluindo 10 classes ausentes no teste (per_class_metrics.csv).

QP3 — Quais falhas são sistematicamente mais difíceis? Resposta. Entre classes **presentes** no teste, **3, 15 e 10** têm os menores F1 médios entre os seis modelos; confusões recorrentes **10→15 e 3→15** (qp3_confused_faults.json, A6 pares). Não se atribui mecanismo físico a essas confusões (INV-08).

QP4 — Métodos mais complexos justificam maior custo? Resposta (descritiva). RF obtém o melhor F1/MCC com treino baixo, porém o maior artefato. XGB quase empata RF com inferência mais rápida e tamanho ~10× menor que RF. GB **não** supera RF/XGB em F1/MCC e tem o maior tempo de treino (≈282 s) — o ganho observado **não** acompanha esse custo neste baseline. SVM linear combina custo alto e pior desempenho preditivo. Fonte: `global_metrics.csv` + `cost_metrics.csv`.

QP5 — Melhor compromisso desempenho × tempo × tamanho? Resposta multicritério (ADR-007; sem vencedor absoluto).

Objetivo	Escolha observacional neste baseline
Maximizar F1/MCC	random_forest (ligeira frente)
Compromisso desempenho/custo	xgboost
Extremo barato com desempenho intermediário	decision_tree
Extremo compacto/rápido com desempenho global baixo	logistic_regression

6.4 Análise estatística formal (SPEC-008)

Fontes: `results/tables/A8_exp-a4-v2__*.csv|json`, `results/metrics/A8_exp-a4-v2__statistics.json`.

Declaração obrigatória	Valor
Unidade experimental	run_id (INV-09 / EST-04)
Número de unidades	11 runs de teste
Métrica pareada	run_accuracy (acurácia <i>dentro</i> de cada run; cada run tem uma única classe verdadeira)
α	0,05
Sementes/splits	1 (limitação EST-01 entre sementes)

Friedman (6 modelos × 11 runs): $\chi^2 = 14,079$; **p = 0,0151**; rejeita H_0 de igualdade de ranks (A8_..._friedman.json).

Resumo por modelo (média ± DP da acurácia por run; IC 95% normal-approx) — A8_..._run_metric_summary.csv:

Modelo	Média run_acc	DP	IC95%
random_forest	0,635	0,267	[0,478; 0,793]
xgboost	0,630	0,288	[0,460; 0,800]
gradient_boosting	0,614	0,278	[0,449; 0,778]
decision_tree	0,579	0,342	[0,376; 0,781]
logistic_regression	0,313	0,315	[0,127; 0,499]

Modelo	Média run_acc	DP	IC95%
svm	0,287	0,306	[0,106; 0,467]

Wilcoxon + Holm - Família planejada **H1** (3 pares ensemble vs LR): todos significativos após Holm (A8_..._wilcoxon_H1_family.csv) → run-level **corroborar** H1 na métrica run_accuracy. - Família planejada **H2** (4 pares RF/XGB vs LR/DT): **nenhum** par permanece significativo após Holm (A8_..._wilcoxon_H2_family.csv) → run-level **não corroborar** H2 (diferenças vs DT pequenas; n=11). - Tabela exploratória all-pairs com Holm global: A8_..._wilcoxon_all_pairs.csv (mais conservadora).

Macro-F1/MCC com C=21 **não** entram como blocos do Friedman (mal definidos por run monoclasa); H3/H4 permanecem critérios §4 sobre métricas/custo globais.

7. Avaliação das hipóteses (H1-H4)

Crítérios binários de SPEC-000 §4 (**corroborada** / **refutada**) sobre métricas globais/custo do holdout, **mais** evidência run-level SPEC-008 onde aplicável.

Dois planos de evidência. (1) §4 sobre F1/MCC/custo globais (A5_...). (2) Friedman/Wilcoxon sobre run_accuracy com n=11 (A8_...). Concordância entre planos não é automática.

H1 — Conjuntos em árvore superam regressão logística (F1 e/ou MCC)

RF, GB e XGB superam LR em F1 macro e em MCC (global_metrics.csv). Critério de refutação (§4) **não** se observa.

Veredito (SPEC-000 §4 / holdout): H1 corroborada.

Veredito run-level (Wilcoxon+Holm, família H1, run_accuracy): corroborada (A8_..._wilcoxon_H1_family.csv; Friedman global p=0,015).

H2 — XGBoost e Random Forest > LR e árvore isolada (F1 e MCC)

RF e XGB superam LR e Decision Tree em F1 macro e MCC globais. Nenhuma desigualdade §4 é violada.

Veredito (SPEC-000 §4 / holdout): H2 corroborada.

Veredito run-level (Wilcoxon+Holm, família H2, run_accuracy): não corroborada — **nenhum** dos quatro pares planejados (RF/XGB vs LR e vs DT) permanece significativo após Holm (A8_..._wilcoxon_H2_family.csv). Nota: RF/XGB vs LR são significativos na família H1 (3 pares), mas deixam de sê-lo sob Holm quando a família cresce para 4 pares em H2; as diferenças médias vs DT são as menores. A superioridade §4 em F1/MCC **não** se traduz em corroboração Wilcoxon de run_accuracy para H2 com n=11.

H3 — LR competitiva em custo; F1 reduzido nas falhas difíceis (QP3)

- **Cláusula de custo (§4):** menor tamanho (10 020 B); 2º menor inferência; 3º menor treino → **está entre os modelos de menor custo** (`cost_metrics.csv`).
- **Cláusula de falhas difíceis (§4):** nas classes de QP3 com `support > 0`, LR apresenta F1 por classe **reduzido** frente aos ensembles em várias falhas (p.ex. 13 e 19); a redução **não** é uniforme em todas as classes difíceis (na classe 3 LR não é a pior absoluta) (`per_class_metrics.csv`).
- **Refutação (§4):** exigiria (i) LR fora do grupo de menor custo **ou** (ii) LR igualar os métodos não lineares em *todas* as classes. Nenhuma das duas se observa.

Veredito (SPEC-000 §4 / holdout): H3 corroborada.

Veredito run-level: não aplicável como teste primário (H3 não é contraste único de acurácia por run).

H4 — Melhor por acurácia ≠ melhor por F1 / MCC / custo de inferência

Critério	Líder observado
Maior acurácia	xgboost (0.618)
Maior F1 macro	random_forest (0.357)
Maior MCC	random_forest (0.597)
Menor inferência	decision_tree (0.0015 s)

O mesmo modelo **não** lidera todos esses critérios.

Veredito (SPEC-000 §4 / holdout): H4 corroborada.

Veredito run-level: não aplicável como contraste Wilcoxon único (H4 é multicritério).

8. Discussão

1. **Multicritério é necessário.** Usar só acurácia elegeria XGBoost; F1/MCC elegem RF; custo de inferência elegeria DT — consistente com H4 (§4) e INV-06/INV-07.
2. **Friedman vs Wilcoxon.** Há evidência global de diferenças entre os seis modelos (Friedman $p=0,015$), mas o poder pareado com $n=11$ é baixo: H1 (família de 3 pares vs LR) passa Holm; H2 (família de 4 pares, incluindo vs DT) não — nenhum dos quatro pares permanece significativo (**AR-5**).
3. **Macro métricas e classes ausentes (AR-4).** BA e F1 macro com $C=21$ incluem zeros por ausência — comparáveis entre modelos no mesmo teste, não “média sobre todas as falhas industriais”.
4. **Seleção vs avaliação (AR-1, AR-2).** Classes de val e teste disjuntas e scorer de acurácia limitam a interpretação dos hiperparâmetros escolhidos na validação.
5. **Orçamentos de busca desiguais (AR-3).** GB (2 candidatos) vs XGB (8); SVM só linear — sem claim de esforço de otimização igual entre famílias.
6. **Sem causalidade física.** Confusões $10 \rightarrow 15$ / $3 \rightarrow 15$ descrevem comportamento dos classificadores (INV-08).

Os riscos AR-1-AR-5 são **aceitos** para este experiment_id (Seção 9.6); não foram removidos por alteração do protocolo congelado.

9. Ameaças à validade

Cobertura das quatro categorias (SPEC-000 §14) e ameaça transversal de reprodutibilidade.

9.1 Validade interna

Ameaça	Situação neste estudo
Vazamento por run	Mitigada: divisão por run_id; leakage_check.status=passed no manifesto A3.
Contaminação do teste na seleção	Mitigada operacionalmente: seleção só em treino/val; teste após freeze (INV-05). Não houve retreino pós-teste.
Fit de transformações fora do treino	Mitigada: preprocessor_v1 fit(train) only.
Protocolos distintos entre modelos	Mitigada: mesmo manifesto e preprocessor (INV-03).
Alinhamento val↔teste de classes	Não mitigada estruturalmente: classes de val e teste disjuntas (limitação do canônico com 2 runs/classe). A seleção por validação não observa as falhas do teste.
Scorer de seleção = acurácia amostral	Parcialmente mitigada em relatório: reconhecida; desalinhada com F1/BA sob desbalanceamento e sob descompasso de classes.

9.2 Validade estatística

Ameaça	Situação
Pseudo-replicação (amostras vs runs)	Mitigada nos testes SPEC-008: agregação por run_id antes de Friedman/Wilcoxon (INV-09). Residual: n=11 e uma semente limitam poder.
Comparações múltiplas	Mitigada: Holm dentro de famílias H1/H2 e tabela all-pairs com Holm (A8_...).
Métrica única	Mitigada na redação: INV-06; custo sempre discutido (INV-07).

Ameaça	Situação
Uma semente	Apenas seed 42; sem replication_seeds nesta rodada — sensibilidade a seed não quantificada.
Orçamentos de busca desiguais	Limitam comparabilidade entre famílias (especialmente GB vs XGB; SVM linear vs RBF futuro).

9.3 Validade de constructo

Ameaça	Situação
Causalidade via importâncias	Mitigada: este relatório não interpreta importância de atributos como física do TEP (INV-08).
“Melhor modelo” = só acurácia F1/BA com C=21 e classes ausentes	Mitigada: QP5 multicritério; H4 explícita. Constructo de “desempenho macro sobre 21 classes” inclui zeros por ausência — documentado; heatmap A6 usa NaN para support=0.
Artefato confused_classes / worst_k	Pode listar classes com support=0; interpretação correta exige filtro por support (feito em QP3).

9.4 Validade externa

Ameaça	Situação
Dados simulados TEP ≠ planta real	Escopo delimitado (SPEC-000 §2.3); generalização industrial não é reivindicada.
Só métodos clássicos	Deliberado (§2.2); referência para estudos futuros profundos/híbridos.
Baseline ≠ tuning SPEC-006A	Resultados não representam o máximo de cada família sob busca ampliada.

9.5 Reprodutibilidade (transversal)

Mitigações: manifesto, seed, snapshot de ambiente, predições e métricas versionadas (REP-01-06). Residual: git_dirty: true no snapshot A4; artefatos A5/A6/análise posteriores ao SHA congelado devem ser commitados em branch dedicada para auditoria completa (GIT-R01-R05). O dry-run permanece marcado scientific_validity: false.

9.6 Riscos metodológicos aceitos (ACCEPTED RISK)

Riscos **estruturais** que exigiriam novo desenho experimental para eliminação e que, para exp-a4-v2, são **aceitos** com mitigação documental (não ocultados):

ID	Finding origem	Mitigação neste estudo	Risco residual
AR-1	MAJOR-02 — valnteste classes vazias	Limitação no manifesto A3; INV-05 (teste isolado); discussão explícita	Hiperparâmetros não otimizados nas falhas do teste
AR-2	MAJOR-03 — scorer = acurácia amostral	Publicação multicritério (INV-06/07); ameaça nomeada	Desalinhamento seleção ↔ F1/BA
AR-3	MAJOR-04 — grids desiguais / SVM linear	Sem claim de esforço igual; YAML versionado	Diferenças misturam família e budget
AR-4	MINOR-03 — macro C=21 com ausentes	Zeros documentados; heatmap NaN; comparação intra-holdout	Macro ≠ cobertura das 21 falhas
AR-5	MINOR-04 — semente única / n=11	SPEC-008 declara unidade e n; H2 run-level não corroborada	Baixo poder; sensibilidade a seed não medida

10. Conclusões

1. O benchmark WP1A executou ponta a ponta o protocolo Auditoria→...→Avaliação(+SPEC-008) para os seis modelos sob exp-a4-v2, com disjunção de run_id e pré-processamento fit-no-treino verificáveis.
2. **QP1-QP5** foram respondidas com evidência em results/ / article/ (Seção 6.3).
3. **H1-H4 corroboradas** pelos critérios §4 no holdout; em run-level, **H1 corroborada** (Wilcoxon+Holm, família 3) e **H2 não corroborada** (família 4; nenhum par após Holm) na métrica run_accuracy (n=11).
4. Não existe um único “melhor modelo”: RF (F1/MCC), XGB (compromisso), DT (custo mínimo) respondem a objetivos distintos (QP5).
5. Conclusões ficam condicionadas aos **riscos aceitos AR-1-AR-5** (Seção 9.6): cobertura disjunta val/teste, scorer de acurácia, grids desiguais, macro com classes ausentes e poder limitado. Remoção desses riscos exige **novo** experiment_id / dataset — não alteração silenciosa de exp-a4-v2.
6. Este relatório (A7) alimenta o manuscrito (A8) e a apresentação (A9); números aqui citados não devem ser reescritos sem o CSV correspondente.

11. Índice de artefatos (rastreabilidade DOC-R03)

Conteúdo	Caminho
Config experimento Snapshot A4	configs/experiments/exp-a4-v2.yaml results/metadata/exp-a4-v2__config_snapshot.json
Manifesto A3 Métricas globais A5	data/processed/split_manifest_v1.json results/tables/A5_exp-a4-v2__global_metrics.csv
Custo A5	results/tables/A5_exp-a4-v2__cost_metrics.csv
Por classe A5	results/tables/A5_exp-a4-v2__per_class_metrics.csv
QP3 JSON	results/tables/A5_exp-a4-v2__qp3_confused_faults.json
Friedman SPEC-008	results/tables/A8_exp-a4-v2__friedman.json
Wilcoxon H1/H2	results/tables/A8_exp-a4-v2__wilcoxon_H1_family.csv, ...__wilcoxon_H2_family.csv
Bundle estatístico	results/metrics/A8_exp-a4-v2__statistics.json
Análise prévia QP/H	reports/technical/A5_exp-a4-v2__scientific_analysis_QP_H.md
Tabelas/figuras A6	article/tables/A6_exp-a4-v2__*, article/figures/A6_exp-a4-v2__*
Traceability A6	results/metadata/A6_exp-a4-v2__traceability.json

12. Referências normativas e bibliográficas mínimas

1. Documento WP1A — *MEI0028_WP1A_3.pdf* (autoridade máxima do subprojeto).
2. docs/project/requirements.md.
3. docs/specs/SPEC-000-master.md (e SPEC-001 a SPEC-009).
4. AGENTS.md — regras operacionais (MET-, LEAK-, DOC-, EXP-).
5. docs/adr/ADR-007-multi-criteria-model-evaluation.md.
6. Downs, J. J., & Vogel, E. F. (1993). A plant-wide industrial process control problem. *Computers & Chemical Engineering*, 17(3), 245–255. (TEP — referência clássica do processo.)
7. Bibliotecas: Pedregosa et al., scikit-learn; Chen & Guestrin, XGBoost — versões no snapshot de ambiente.

Referências bibliográficas amplas de diagnóstico de falhas / TEP serão expandidas no manuscrito A8.

Apêndice A — Checklist de aceite tocado por A7

Critério	Status neste documento
CA-07 QP1-QP5 explícitas	Cumprido (Seção 6.3)
CA-08 H1-H4 avaliadas	Cumprido (Seção 7): cada H com veredito binário corroborada/refutada + box SPEC-008
CA-10 ameaças (4 categorias)	Cumprido em A7 (Seção 9); estrutura completa de 10 seções aplica-se a A8
DOC-R03 rastreabilidade	Cumprido (Seção 11)
INV-06 / INV-07 / INV-08	Respeitados na redação

Fim do Relatório Técnico A7 — experimento exp-a4-v2.